

# Herramientas de Teledetección Cuantitativa

## Clase 4

Francisco Nemiña

Unidad de Educación y Formación Masiva  
Comisión Nacional de Actividades Espaciales



# Esquema de presentación

## Clasificaciones temáticas

Escenas del capítulo anterior

Nueva idea

## Clustering

Introducción

k-means

Problemas


isodata

## Consideraciones finales

Técnicas pos-clasificación

## Práctica





## Mapas temáticos

Queremos cambiar de información espectral a categorías. Seguimos reduciendo la dimensionalidad de la imagen con otras técnicas.



# Nueva idea





Imagen de la zona de interés en combinación RGB.



# Nueva idea




Clustering en  $R^2$ .<sup>1</sup>

---

<sup>1</sup>Wikimedia Commons. *SLINK Gaussian data*. 2011.





Mapa temático de la zona de interés.




## ¿Cómo?

Realizando clasificaciones en el espacio vectorial de la imagen.  
Estos algoritmos se van a basar en los valores individuales de cada vector (píxel)





# Nueva idea



Línea de tiempo de distintos métodos de clasificación.<sup>2</sup>

<sup>2</sup><http://gisgeography.com>. *Image Classification Techniques in Remote Sensing*.



# Esquema de presentación

## Clasificaciones temáticas

Escenas del capítulo anterior

Nueva idea

## Clustering

Introducción

k-means

Problemas

isodata

## Consideraciones finales

Técnicas pos-clasificación

## Práctica



## Distancia

Para poder trabajar cómodos en el espacio vectorial vamos a tener que definir la distancia entre dos vectores

$$d(\rho_1, \rho_2) = (|\rho_{1,i} - \rho_{2,i}|^p)^{1/p}$$



## Taxisita

Cuando  $p = 1$  tenemos

$$d(\rho_1, \rho_2) = (|\rho_{1,i} - \rho_{2,i}|)$$

## Euclídea

Cuando  $p = 2$  tenemos

$$d(\rho_1, \rho_2) = (|\rho_{1,i} - \rho_{2,i}|^2)^{1/2}$$



## Criterio habitual

Encontrar clases  $c_i$  que minimice

$$SSE = \sum_{c_i} \sum_{x \in c_i} (x - x_i)^2$$

donde  $x_i$  es el promedio de todos los valores de cada clase.



## Una solución

Si  $c_i = x_i$  esto da cero y es mínimo. Entonces tiene al menos una solución.

## Otras soluciones

Tenemos que encontrar  $N$  categorías  $c_i$  que minimicen esto.



## Cuentas

Esto son MUCHAS cuentas y tomaría mucho tiempo. Tenemos que buscar otra manera más eficiente de hacerlo.



## Ejemplo en 1-D

Edades.





# k-means










Imagen a clasificar.<sup>3</sup>

---

<sup>3</sup>Andrei Pandre. *Cluster Analysis: see it 1st.*



# k-means




Proceso paso a paso.<sup>4</sup>



<sup>4</sup>Andrei Pandre. *Cluster Analysis: see it 1st.*

# k-means

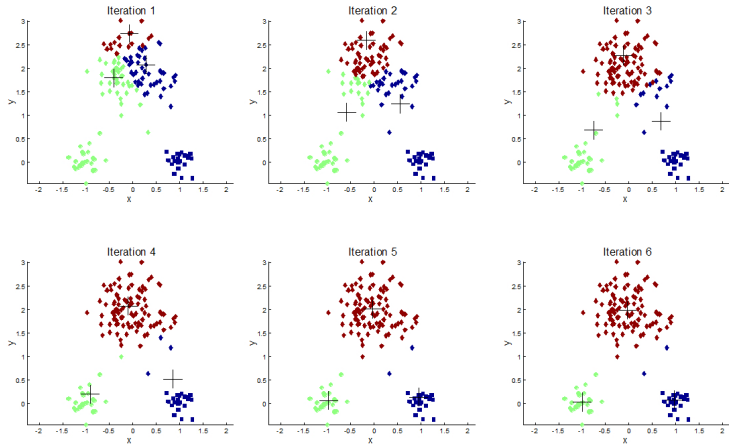


Proceso paso a paso.<sup>5</sup>

<sup>5</sup>Andrei Pandre. *Cluster Analysis: see it 1st*.



# k-means



Proceso paso a paso.<sup>6</sup>




<sup>6</sup>Andrei Pandre. *Cluster Analysis: see it 1st.*

## Descripción del algoritmo

1. Selecciono N clases iniciales
2. Asigno los píxeles a estas clases
3. Calculo los centroides de las clases clasificadas
4. Repito 2 - 4 con los nuevos centroides hasta converger




# k-means



Y que pasa con la función de SSE a minimizar.<sup>7</sup>

<sup>7</sup> John A Richards. *Remote Sensing Digital Image Analysis*. Springer, 2013.





Mínimo local vs. mínimo global en 1-D.<sup>8</sup>



## Selección inicial de clases

Lo que determina a qué mínimo converge es la selección inicial de clases. Además no siempre me garantizo generar  $N$  clases, puedo generar menos de las deseadas.

## Como elijo las medias iniciales

- ▶ De forma estocástica
- ▶ Con algún criterio estadístico






## Diferencias con respecto a kmeans

El algoritmo es básicamente el mismo, pero implementa tres condiciones adicionales.

- ▶ Eliminar cluster si no son estadísticamente relevantes.
- ▶ Fusionar cluster si espectralmente son similares.
- ▶ Partir clusters que son muy alargados.





Clasificación no supervisada por isodata.<sup>9</sup>



# Esquema de presentación

## Clasificaciones temáticas

Escenas del capítulo anterior

Nueva idea

## Clustering

Introducción

k-means

Problemas

isodata

## Consideraciones finales

Técnicas pos-clasificación

## Práctica




## Filtrado

Nos va a permitir reducir algunos mitigar una limitación común en la clasificación como es la existencia de parches de escasa superficie. Suavizan las clasificaciones.



# Técnicas pos-clasificación



Ejemplo de filtrado por mayoría.<sup>10</sup>

<sup>10</sup>ArcGIS 9.2 Desktop Help. *Majority Filter*.



## Fusión

Nos permite convertir las clases de clasificación generadas por algún algoritmo en clases temáticas.



# Técnicas pos-clasificación




Imagen con clases fusionadas.



# Técnicas pos-clasificación




Imagen con clases fusionadas.





# Técnicas pos-clasificación




Imagen con clases fusionadas.



# Esquema de presentación

## Clasificaciones temáticas

- Escenas del capítulo anterior

- Nueva idea

## Clustering

- Introducción

- k-means

- Problemas

- isodata

## Consideraciones finales

- Técnicas pos-clasificación

## Práctica



## Actividades prácticas de la cuarta clase

1. Abrir imágenes Landsat 8 y digitalizar coberturas de interés.
2. Clasifique la imagen por el método k-means con 7 clases.
3. Clasifique la imagen por el método k-means con 70 clases.
4. Utilizar la herramienta de estadísticas globales para estimar las áreas correspondientes a cada uso y cobertura.

